

Spatio-Temporal Voxel Layer ile Geometrik Derinlik Süreksizliği Tabanlı Negatif Engel Tespiti ve Tam Nav2 Entegrasyonu

Yazar Adı, Üye, IEEE, ve Ortak Yazar, Üye, IEEE

Abstract—Standart Robot İşletim Sistemi 2 (ROS 2) navigasyon yığınları — Nav2 ve Spatio-Temporal Voxel Layer (STVL) bileşenleri dahil — mobil robotlar için çukur, platform kenarı ve merdiven inişi gibi *negatif engelleri* üstünü kapatamamaktadır; bu bölgeler costmap'te boş alan olarak görünür ve düşme kazalarına yol açan temsil boşluğu oluşturur. Bu çalışmada tek bir RGB-D kameradan öğrenmesiz geometrik analiz ile bu boşluğu kapatan hafif, gerçek-zamanlı bir çerçeve sunulmaktadır. Yöntemimiz dört katkıdan oluşur: (i) RANSAC zemin tahminini derinlik süreksizliği analiziyle birleştiren ve dört sınıflı risk maskası üreten *geometrik risk tahmin modülü*; (ii) düşme kenarlarını zamansal kalıcılıkla PointCloud2'ye dönüştüren *projeksiyon borusu*; (iii) sentezlenmiş bulutu ikincil STVL gözlem kaynağı olarak kullanan ve STVL C++ çekirdeğine dokunmayan parametre-tabanlı entegrasyon; (iv) hem yerel STVL costmap'te hem de global ObstacleLayer'da düşme bölgelerini işaretleyerek planlayıcının bu bölgelerden baştan kaçındığı *iki katmanlı koruma mimarisi*. Tam Nav2 yığını entegrasyonu (Regulated Pure Pursuit, NavFn, BT yönlendiricisi, davranış sunucusu, AMCL, GPS-EKF) yalnızca parametre arayüzü üzerinden gerçekleştirilmiştir. 9 sahne tipi ve 110 zor-negatif vakayı kapsayan 340 örneklik sentetik veri setinde YHO=0.286 yanlış güvenli oranı ve 0.714 düşme geri çağırma oranı ile ortalama 41 ms kare gecikmesi elde edilmiş olup, sistem CPU-tek çalışan gömülü platformlara (Raspberry Pi 5 sınıfı) uygun bir hesaplama profili sunar.

Index Terms—Negatif engel tespiti, RGB-D algı, costmap tabanlı navigasyon, ROS 2/Nav2, geçiş kabiliyeti, mobil robot güvenliği.

I. GİRİŞ

NEGATIF engeller — çukurlar, platform kenarları, merdiven inişleri, hendekler ve kaldırım düşüşleri — otonom mobil robotlar için sıkça ihmal edilen kritik bir tehlike sınıfıdır. Pozitif engellerin aksine negatif engeller, mesafe sensörü enerjisini geri yansıtacak bir yüzey içermez; bu nedenle 2.5B ya da 3B vksel temsillerden bu bölgeler ya *boş alan* olarak görünür ya da sensör kapsama alanı dışında sayılır. Günümüz ROS 2/Nav2 yapıları [1], [2] ve onun en yaygın algı eklentisi olan STVL [3], bu temsil boşluğuna yapısal olarak duyarsızdır: STVL, RGB-D nokta bulutlarından ölümcül vksel işaretlemesi ve zamansal çözünme yapar; ancak *destek yokluğu* kavramını modelleme yeteneğinden yoksundur.

Makale XXXX tarihinde gönderilmiş, XXXX tarihinde kabul edilmiştir. Bu çalışma [Burs/Kurum] tarafından kısmen desteklenmiştir.

Yazarlar [Kurum], [Şehir], Türkiye ile ilişkilidir (e-posta: dr.oguz.misir@gmail.com).

Tekrarüretilebilir kaynak kodu ve sentetik veri seti <https://github.com/<repo>> adresinde mevcuttur.

Dijital Nesne Tanımlayıcısı (DOI): XX.XXXX/LRA.20XX.XXXXXXX

Bu durum bir uygulama yetersizliği değil, köklu bir *temsil boşluğudur*.

LiDAR tabanlı yöntemler [4]–[6] yapılandırılmamış arazilerde umut vaad eden sonuçlar verir; ancak yoğun LiDAR'ın maliyet, yer ve enerji bütçesi gömülü/iç mekan robotlarının çoğuna uygun değildir. Öğrenme tabanlı arazi değerlendirme yöntemleri [7], [8] güçlü performış sunar; ancak geçiş kabiliyeti etiketli kapsamlı veri ile eğitim gerektirir ve dağılım dışı (out-of-distribution) geometrilerde sessizce başarısız olabilir. Bu çalışma; gerçek-zamanlı, öğrenmesiz, tek RGB-D kamera tabanlı ve *mevcut Nav2/STVL altyapısına olabildiğince az dokunan* bir orta yolu hedeflemektedir.

Bu çalışmanın temel teorik katkısı, düşme kenarlarını hem yerel costmap (STVL'in ikinci gözlem kaynağı) hem de global costmap (yeni ObstacleLayer eklentisi) içine dahil ederek planlayıcının bu bölgelerden *plan aşamasında* kaçınmasını sağlayan **iki katmanlı costmap koruma mimarisidir**. Standart Nav2 yapılandırması ise yalnızca yerel kontrolcü düzeyinde *reaktif* kaçınım sağlar; global planlayıcı düşme bölgelerini ihlal eden güzergahlar üretmeye devam edebilir.

Katkılar. Bu makalenin spesifik katkıları:

- Tek RGB-D kameradan gerçek-zamanlı geometrik negatif engel tespit çerçevesi: zemin tahmini, derinlik süreksizliği analizi ve zamansal kalıcılığı entegre eden iki algoritma sunulmuştur (Alg. 1–2, Bölüm IV).
- STVL C++ çekirdeğini değiştirmeden, yalnızca yapılandırma arayüzü aracılığıyla gerçekleştirilen *iki katmanlı Nav2 costmap koruma mimarisi* (Bölüm IV-E).
- Regulated Pure Pursuit kontrolçüsü [9], NavFn planlayıcı, BT yönlendiricisi, davranış sunucusu ve dual-EKF tabanlı GPS-IMU lokalizasyon [10] bileşenlerinin entegre edildiği, iç-mekan ve dış-ortam navigasyonunu kapsayan tam yığın (Bölüm IV-F).
- Açık zor-negatif vakaları (gölge, parlak zemin, rampa) içeren ve sahne bazında bölünmüş sentetik değerlendirme protokolü (Bölüm V).
- Beş konfigürasyonlu ablasyon çalışması, hiperparametre duyarlılığı analizi ve standart STVL temel çizgisi ile karşılaştırma (Bölüm VII).
- Açık kaynak ROS 2 paketleri ve tekrarüretilebilir veri seti.

II. İLGİLİ ÇALIŞMALAR

A. Negatif Engel Tespiti

Erken çalışmalar negatif engelleri stereo görüşün eksik dönüş imzası [11] ve LiDAR irtifa haritası analizleri [4], [5]

üzerinden modellemiştir. Morton ve Olson [6], HLD (yatay-uzunluk-derinlik) sınıflandırıcısıyla pozitif ve negatif engelleri birleşik bir geometrik çerçevede ele almıştır. Termal imza analizi [12] gece koşulları için incelenmiştir. Bu yaklaşımlar işlevselliği açısından güçlü olsa da çoğu kez çoklu-modal algı (LiDAR + IMU + termal) ve açık hava ortamını hedeflemektedir; gerçek-zamanlı entegrasyon, costmap tabanlı planlayıcılarla nasıl eşleştirileceği açıkça ele alınmamıştır. Bizim katkımız, tek RGB-D ile elde edilen geometrik süreksizlik bilgisinin Nav2/STVL ekosistemine sistemik bir şekilde gömüldüğü, ilk uçtan-uca entegrasyonu sağlamasıdır.

B. Geçiş Kabiliyeti ve Arazi Analizi

RGB-D tabanlı geçiş kabiliyeti [13], [14] yüzey normal analizi, eğim hesabı ve voksel haritalama üzerinden incelenmiştir. Öğrenme tabanlı yöntemler [7], [8], kendi-denetimli imza çıkarımıyla güçlü performans sergiler; ancak dağılım dışı sahnelerde sessiz hatalar verebilir ve genelde geri dönüşsüz bir tabakaya karşı *açıkça* korumalı değildir. Risk tabanlı planlama [15], geçiş maliyetini deterministik olmayan bir alan olarak modellemeyi sağlar; ancak algı tarafındaki temsil boşluğu (negatif engel = boş alan) sorununu çözmez.

C. 3B Doluluk ve Voksel Haritalama

OctoMap [16] olasılıksal ağaç tabanlı 3B haritalama sağlar; Voxelblox [17] ve onun türevi STVL [3] üstünü zamansal voksel temsilleri ekler. Yüksekliğe dayalı yöntemler [18], [19] geçiş kabiliyetini doğrudan elevation map'ten türetir ve adımlama-kontrol robotları için standart hale gelmiştir. **Kritik fark:** Bu çalışmaların hiçbiri *geri dönüşü olmayan bölgenin görünmemesi* probleminin Nav2 ekosistemindeki sistemsel çözümünü tartışmaz; bizim katkımız bu yapısal boşluğu Nav2 mimarisi içinde kalarak doldurmaktır.

D. Costmap Tabanlı Navigasyon ve Nav2

Lu ve ark. [20] katmanlı costmap mimarisini sunmuştur; bu mimari Nav2'nin [1], [2] algı-planlama omurgasını oluşturur. Standart Nav2 dağıtımı, NavFn (Dijkstra) global planlayıcı, RPP (Regulated Pure Pursuit) [9] kontrolçü, davranış sunucusu, AMCL ve yaşam döngüsü yöneticisini birleştirir. STVL'nin yapılandırılabilir nokta-bulutu gözlem kaynağı mekanizması [3], sentezlenmiş algı çıktılarını çekirdek kodu değiştirmeden enjekte etmek için doğal bir arayüzdür.

E. Sürekli Risk Alanı ve Kontrol Bariyeri

Negatif engelleri *soft constraint* olarak modelleyen klasik potansiyel alan [21] yöntemleri yerel minimumlara sıkışabilir. Daha modern control barrier function (CBF) çerçeveleri [22], durum kısıtlamalarını optimizasyona enjekte ederek formal güvenlik garantileri sağlar; ancak CBF'in çalışması için negatif engel bölgelerinin algı tarafından *doğru şekilde görünmesi* ön koşuldur. Bizim sağladığımız costmap-düzeyinde temsil, gelecekte CBF tabanlı bir kontrolçü için de altyapı oluşturacaktır.

III. PROBLEM TANIMI

A. Robot ve Sensör Modeli

Diferansiyel sürürlü 4WD bir mobil robot çalıştırıyoruz; ileri kinematik $\dot{\mathbf{p}} = R(\theta)[v \ 0]^T$, $\dot{\theta} = \omega$ olup $\mathbf{p} = [x, y]^T$ konum, θ yön, v ve ω sırasıyla doğrusal ve açısal hızlardır ($|v| \leq v_{\max} = 0.5$ m/s, $|\omega| \leq \omega_{\max} = 1.5$ rad/s). Robot, `base_link` çerçevesinde sabit montaj pozıyla (URDF: $z_c=0.27$ m yükseklik, -20° eğim) bir RGB-D kamerayla donatılmıştır. Her kare, derinlik görüntüsü $D: \Omega \rightarrow \mathbb{R}_{\geq 0} \cup \{\infty\}$ ve iç parametre matrisi K ile birlikte gelir; burada $\Omega \subset \mathbb{Z}^2$ piksel uzayıdır.

B. Negatif Engel Tanımı

$\mathbf{X}(u, v) = K^{-1}[u, v, 1]^T \cdot D(u, v)$ piksel (u, v) 'nin 3B noktası olsun. RANSAC ile tahmin edilen zemin düzlemi $\pi: \mathbf{n}^T \mathbf{X} + d_0 = 0$ verildiğinde, negatif engeli aşağıdaki gibi tanımlıyoruz:

$$\mathcal{D} = \{(u, v) \in \Omega : J(u, v) > \theta_j \wedge \mathbf{n}^T \mathbf{X}(u, v) < -h_{\text{safe}}\} \quad (1)$$

burada $J(u, v) = \max_{(du, dv) \in \mathcal{N}} |D(u+du, v+dv) - D(u, v)|$ derinlik atlama haritası, $\theta_j = 0.12$ m süreksizlik eşiği, ve $h_{\text{safe}} = 0.05$ m güvenli yükseklik toleransıdır. $\mathcal{N}$ ise 3×3 komşuluğu temsil eder.

Piksel-bazında geçiş kabiliyeti riski dört kategorik etiketten birine atanır:

$$R(u, v) \in \mathcal{R} = \{\text{GUVENLI}, \text{BELIRSIZ}, \text{KATI}, \text{DROP}\}$$

C. Güvenlik Metriği ve Kısıt

Birincil güvenlik metriği *Yanlış Güvenli Oranı (YHO)*:

$$\text{YHO} = \frac{|\{(u, v) : R_{\text{gt}}=\text{DROP} \wedge R_{\text{pred}}=\text{GUVENLI}\}|}{|\{(u, v) : R_{\text{gt}}=\text{DROP}\}|} \quad (2)$$

YHO, gerçekten düşme olan bölgelerin sistem tarafından *güvenli* olarak yanlış etiketlenmesi olasılığıdır; navigasyon için en kritik hatadır ve azaltılması görev hedefinin önündedir.

D. Optimizasyon Formülasyonu

Robotun zaman-ayrık navigasyon hedefi, T ufuk üzerinde ortalama maliyet J^* 'yi *negatif engel kısıtı* altında minimize etmektir:

$$\begin{aligned} \min_{\mathbf{u}_{0:T-1}} \quad & \sum_{t=0}^{T-1} \ell(\mathbf{x}_t, \mathbf{u}_t, \mathbf{g}) \\ \text{s.t.} \quad & \mathbf{x}_{t+1} = f(\mathbf{x}_t, \mathbf{u}_t) \\ & \text{dist}(\mathbf{x}_t, \mathcal{D}_{\text{world}}) > r_{\text{safe}} \quad \forall t \in [0, T] \end{aligned} \quad (3)$$

burada $\ell(\cdot)$ hedef-g'a uzaklık ve kontrol enerjisi maliyeti, $\mathcal{D}_{\text{world}} \subset \mathbb{R}^3$ dünya çerçevesinde negatif engellerin saptığı 3B bölgedir ve $r_{\text{safe}} = 0.35$ m güvenli mesafe. Costmap'ın görevi $\mathcal{D}_{\text{world}}$ 'ü planlayıcıya geçirmek; kontrolçünün görevi ise (3)'ü sağlayan $\mathbf{u}_t$ dizüğü üretmektir. Bu makale, $\mathcal{D}_{\text{world}}$ 'ün costmap'te *sadık* biçimde temsil edilmesi probleminde odaklanır.




Fig. 1. Boru hattı genel bakışı. Tek RGB-D kameranın derinlik akışı geometrik risk tahmini, düşme kenarı çıkarımı, 3B projeksiyon ve zamansal kalıcılık aşamalarından geçerek /semantic_drop_points'a beslenir. Bu konu hem yerel STVL hem de global ObstacleLayer tarafından işlenir. STVL C++ çekirdeği değiştirilmemiştir.

IV. ÖNERİLEN YÖNTEM

A. Sistem Genel Bakışı

Boru hattı dört aşamalıdır (Şekil 1): (1) geometrik risk tahmini (Alg. 1), (2) düşme kenarı çıkarımı ve 3B projeksiyon (Alg. 2), (3) zamansal kalıcılık ile /semantic_drop_points yayını, (4) iki katmanlı Nav2 costmap entegrasyonu. Tüm boru hattı CPU-tek çekirdek üzerinde ~ 41 ms ortalama gecikme ile 10 Hz'de çalışır.

B. Geometrik Risk Tahmini

Zemin düzlemi tahmini. Sonlu derinlik piksellerinin altkütmesi $\Omega_f \subset \Omega$ üzerinde RANSAC [23] kullanırız: $N_{it} = 50$ iterasyonda rastgele seçilen 3 noktayla aday düzlem π' üretilir ve $|\mathbf{n}'^T \mathbf{X} + d'_0| < \epsilon_{\text{plane}}$ ($= 0.03$ m) sağlayan inlier sayısı en yüksek olan önâ çıkarılır. İnlier kümesi üzerinde SVD ile son düzlem parametreleri rafine edilir. Normal $\mathbf{n}$, kamera optik eksenine bakacak şekilde işaret normalize edilir.

Risk maskası üretimi. Alg. 1, $R(u, v)$ etiketlerini hesaplar. 3B koordinatı zemin düzlemine $|\mathbf{n}^T \mathbf{X} + d_0| \leq h_{\text{safe}}$ olan pikseller GUVENLİ; geçersiz derinliğe ($D=\infty$ veya NaN) sahip pikseller BELIRSIZ; zemin düzlemi üzerinde ($\mathbf{n}^T \mathbf{X} + d_0 > h_{\text{safe}}$) pikseller KATI; (1) tanımını sağlayan pikseller ise DROP olarak işaretlenir.

Karmaşıklık. Algoritma 1 her piksel üzerinde $O(1)$ işlem yapar; toplam karmaşıklık $O(|\Omega|)$ 'dır. RANSAC aşaması $O(N_{it} \cdot |\Omega_f|)$ olup 640×480 çözünürlük için ortalama 7 ms sürer.

C. Düşme Kenarı Çıkarımı ve 3B Projeksiyon

Kenar maskası. DROP bölgelerinin sınır piksellerini morfolojik çıkarım $E = \text{DROP} \setminus \text{erode}_{3 \times 3}(\text{DROP})$ ile elde ederiz. Bu, robotun ulaşamayacağı uzak çukur içlerini aşırı işaretlemekten kaçınır; bulutu sadece erişilebilir tehlike sınırına odaklar.

3B projeksiyon. Her aktif kenar piksel $(u, v) \in E$ iğnelik modeliyle 3B'ye projekte edilir:

$$\mathbf{X}_c = \begin{bmatrix} (u-c_x) D(u, v) \\ (v-c_y) D(u, v) \\ D(u, v) \end{bmatrix} \quad (4)$$

Sonlu derinliğe sahip olmayan kenar pikselleri için en yakın sonlu komşu kullanılır. Bunlar daha sonra URDF'den elde

Algorithm 1 Geometrik Risk Maskası Üretimi

Require: Derinlik görüntüsü D , kamera matrisi K , eşikler

$\theta_j, h_{\text{safe}}$

Ensure: Piksel-bazında risk maskası R

```

1:  $\Omega_f \leftarrow \{(u, v) : D(u, v) \text{ sonlu}\}$ 
2:  $(\mathbf{n}, d_0) \leftarrow \text{RANSAC\_Plane}(\{\mathbf{X}(u, v)\}_{\Omega_f})$ 
3:  $\mathbf{n} \leftarrow \text{sgn}(\mathbf{n}_z) \cdot \mathbf{n}$  // optik eksene yönlendir
4:  $J \leftarrow \text{MaxJump}_{3 \times 3}(D)$  // (1)
5: for all  $(u, v) \in \Omega$  do
6:   if  $D(u, v) = \infty$  or  $D(u, v)$  NaN then
7:      $R(u, v) \leftarrow \text{BELIRSIZ}$ 
8:   else
9:      $h \leftarrow \mathbf{n}^T \mathbf{X}(u, v) + d_0$ 
10:    if  $J(u, v) > \theta_j$  and  $h < -h_{\text{safe}}$  then
11:       $R(u, v) \leftarrow \text{DROP}$ 
12:    else if  $h > h_{\text{safe}}$  then
13:       $R(u, v) \leftarrow \text{KATI}$ 
14:    else
15:       $R(u, v) \leftarrow \text{GUVENLİ}$ 
16:    end if
17:  end if
18: end for
19: return  $R$ 

```

Algorithm 2 Düşme Kenarı Çıkarımı ve Kalıcı Bulut Üretimi

Require: Risk maskası R , derinlik D , kamera matrisi K , T_{cb} , zaman pencere T_w

Require: Persistent buffer $\mathcal{B}$ (FIFO, zaman damgalı)

Ensure: Yayın bulutu $\mathcal{C} \in \text{base_link}$

```

1:  $\text{DROP} \leftarrow \{(u, v) : R(u, v) = \text{DROP}\}$ 
2:  $E \leftarrow \text{DROP} \setminus \text{erode}_{3 \times 3}(\text{DROP})$ 
3:  $\mathcal{P} \leftarrow \emptyset$ 
4: for all  $(u, v) \in E$  do
5:    $\mathbf{X}_c \leftarrow \text{Project3D}(u, v, D, K)$  // (4)
6:    $\mathbf{X}_b \leftarrow T_{cb} \cdot \mathbf{X}_c$ 
7:    $\mathcal{P} \leftarrow \mathcal{P} \cup \{(\mathbf{X}_b, t_{\text{now}})\}$ 
8: end for
9:  $\mathcal{B} \leftarrow \mathcal{B} \cup \mathcal{P}$ 
10:  $\mathcal{B} \leftarrow \{(\mathbf{X}, t) \in \mathcal{B} : t_{\text{now}} - t \leq T_w\}$ 
11:  $\mathcal{C} \leftarrow \text{VoxelDownsample}(\mathcal{B}, \text{leaf}=0.05)$ 
12: return  $\mathcal{C}$ 

```

edilen statik kamera-baseLink dönüşümü $T_{cb} \in SE(3)$ ile base_link'e taşınır.

Zamansal kalıcılık. Kare gürültüsüne ve kısa kapanmalara karşı kararlılığı sağlamak için noktalar $T_w = 1.5$ s süreli kayan pencerede biriktirilir. Voksel-ışızarası örneklem (yaprak boyutu 0.05 m) bulut boyutunu sınırlandırır; T_w 'den eski noktalar atılır. Sonuç bulutu /semantic_drop_points olarak 10 Hz'de yayınlanır.

D. STVL Yerel Costmap Entegrasyonu

STVL, RGB-D nokta bulutu kaynaklarını bağımsız marking/clearing davranışlarıyla yapılandırabilen gözlem kaynakları aracılığıyla kabul eder. İki kaynak tanımlan-

TABLE I
STVL GÖZLEM KAYNAĞI YAPILANDIRMASI

Parametre	depth_camera	drop_edges
data_type	PointCloud2	PointCloud2
topic	/camera/depth/points	/semantic_drop_points
marking	true	true
clearing	true	false
obstacle_range	3.5 m	3.5 m
raytrace_range	4.0 m	0.0 m
min_obstacle_height	-0.1 m	-0.5 m
max_obstacle_height	2.0 m	0.3 m

miştir: (1) RGB-D derinlik nokta bulutu (depth_camera), (2) Bölüm IV-C'daki sentezlenmiş bulut (drop_edges).

Marking-only davranışı. depth_camera kaynağı hem marking hem clearing yapar; drop_edges kaynağı ise clearing:false yapılandırmasıyla *yalnızca marking* olarak çalıştırılır. Bu ayırım kritiktir: eğer düşme kaynağı clearing yapsaydı, derinlik kameranın ışın tüpleri düşme işaretlerini silebilirdi. Marking-only sayesinde işaret, robot o bölgeyi görüş alanından kaybetse bile korunur.

Voksel bozunma modeli. STVL'nin doğrusal bozunma modelinde voksel maliyeti $C(t)$:

$$C(t) = 254 \cdot \exp(-\lambda t), \quad \lambda = \frac{\ln 2}{T_{\text{decay}}} \quad (5)$$

$T_{\text{decay}} = 15$ s, 10 Hz sistemde yaklaşık 150 güncellemeye karşılık gelir. Algoritma 2'nin ürettiği $T_w=1.5$ s'lik kalıcılık penceresi nedeniyle düşme kenar voksellerinin maliyeti her yeni örnekleme 254'e tazelenir; pratikte $C(t) \approx 254$ sabit kalır.

Inflation katmanı etkileşimi. STVL'in çıktısının üstünde gelen InflationLayer, ölümcül hücreleri saran maliyet gradyanı üretir:

$$C_{\text{infl}}(d) = \lfloor 252 \cdot e^{-\sigma_c(d-r_{\text{robot}})} \rfloor, \quad d < r_{\text{infl}} \quad (6)$$

burada $\sigma_c = 3.0$, $r_{\text{robot}} = 0.22$ m. Bu gradyan, RPP kontrolçüsünün düşme bölgelerine yönelmesini cezalandırır. Tablo I her iki kaynak için kritik parametreleri özetler.

E. İki Katmanlı Nav2 Costmap Koruma Mimarisi

Standart yapılandırmanın eksikliği. Tipik bir Nav2 dağıtımında STVL yalnızca 5×5 m kayan pencereli yerel costmap'te bulunur. Global costmap ise statik harita ve ObstacleLayer ile çalışır ve sentezlenmiş algı kaynaklarını varsayılan olarak işlemez. Bu, NavFn'in düşme bölgelerini ihlal eden güzergahlar planılamasına yol açar: robot bu bölgenin yakınına geldiğinde sadece yerel kontrolçü (RPP) *reaktif* olarak duracaktır ki bu, köşeyle karşılaştığında yetersiz kalabilir.

Önerilen mimari. /semantic_drop_points hem yerel costmap'e (STVL ikinci kaynağı) hem de global costmap'e (drop_edge_layer: ayrı bir ObstacleLayer eklentisi) eşzamanlı beslenir. Böylece NavFn, planlama aşamasında düşme bölgelerini *görür* ve onlardan kaçınan güzergahlar üretir. Tablo II iki katmanın işlevsel ayırımını verir; Şekil 2 mimarinin görsel sonucunu gösterir.

Korumalı navigasyon döngüsü.

Fig. 5 — STVL Local Costmap with Semantic Drop-Edge Markings (Simulated pit scene, 5×5 m window, 0.05 m/cell)




Fig. 2. STVL yerel costmap ile semantik düşme kenarı işaretleri (sol: 5×5 m kuş bakışı; sağ: orta sütun maliyet profili). Ölümcül hücreler (maliyet = 254) çukur sınırında bariyer oluşturur.

TABLE II
İKİ KATMANLI COSTMAP KORUMA MIMARISI

Costmap	Eklenti	Görev
Yerel	STVL	/semantic_drop_points + RGB-D; 15 s zamansal hafıza; RPP anlık kaçınma
Global	drop_edge_layer	/semantic_drop_points; NavFn düşme bölgelerinden baştan kaçınır

- 1) *Global planlayıcı düzeyi:* NavFn, düşme bölgelerini önceden görür ve onlardan kaçınır. Robot kenara yaklaşmaz.
- 2) *Lokal kontrolçü düzeyi:* STVL, henüz haritalanmamış yeni düşme kenarları için ikincil güvenlik katmanındır; 15 s zamansal hafızayla kare gürültüsüne karşı stabildir.
- 3) *Kurtarma davranışları:* Kontrolçü takip edemezse davranış sunucusu *geri çekil, dön veya yeniden planla* dizisini tetikler.

F. Tam Nav2 Yığının Entegrasyonu

Sistem, STVL çekirdeğine dokunmadan, yalnızca parametre arayüzü üzerinden eksiksiz bir Nav2 yığımıyla entegre edilmiştir (Tablo III).

Üç operasyon modu. Sistem tek bir launch komutuyla üç moda çalıştırılabilir: (i) haritasız iç mekan (odometre-tek, 10×10 m kayan global costmap), (ii) haritalı (AMCL map→odom TF üretir), (iii) dış-ortam GPS modu (Şekil 3). GPS modu, NMEA GPS sürücüsü, Wit-motion HWT905 IMU, ve robot_localization paketinin dual-EKF konfigürasyonunu kullanır: yerel EKF (ekf_local) tekerlek odometri ve IMU'yu birleştirerek 30 Hz'de odom→base_link TF üretir; global EKF (ekf_global) navsat_transform [10]'ün ürettiği ENU odometriyle GPS düzeltmesi yapar ve map→odom TF üretir. Bu, dış ortamda haritasız navigasyonu mümkün kılar; aynı negatif engel boru hattı (20×20 m global kayan pencereyle) değişmeden çalışır.

Donanım köprüsü. Gerçek robotta, ROS 2'nin /cmd_vel konusu Arduino Mega tabanlı diferansiyel motor sürücüsü aracılığıyla donanıma aktarılır. Sürücü, L R\ n formatında PWM çiftleri gönderir; tekerlek hız oranlarını /wheel_odom ve /wheel_rpm olarak 10 Hz'de yayımlar. 400 ms taze-

TABLE III
ENTEĞRE EDİLEN TAM NAV2 YİĞİNİ BİLEŞENLERİ

Bileşen	Uygulama	Seçim Gerekçesi
Lokal kontrol	RPP [9]	Diferansiyel uyumu
Global plan	NavFn (Dijkstra)	Düşük hesaplama
Davranış	BackUp, Spin, Wait	Standart kurtarma
BT yönlendir.	Nav2 BT Navigator	Yeniden planlama
Hız düzenle.	VelocitySmoother	PWM rampalama uyumu
Konum (iç mek.)	AMCL (harita varsa)	Odometre-tek de mevcut
Konum (dış or.)	dual-EKF [10] + NavSat	GPS-IMU füzyon
Yaşam döng.	LifecycleManager	Otomatik başlatma

[GPS modu TF ağacı ve veri akışı şeması]

Fig. 3. Dış ortam GPS modu mimarisi. NMEA GPS ve Witmotion IMU sürücülerini dual-EKF füzyonuyla map→odom→base_link TF zincirini üretir; aynı negatif engel costmap'ı map çerçevesinde çalışır.

lik penceresi karşılandığında komut kabul edilir; aksi halde 500 ms içinde güvenli STOP gönderilir.

V. SENTETİK VERİ SETİ VE DEĞERLENDİRME PROTOKOLÜ

Veri seti. Gazebo Harmonic [24] üzerinde 9 sahne tipi için 340 örneklik sentetik veri seti oluşturduk: çukur, platform kenarı, merdiven inişi, hendek, kaldırım düşüşü, düzensiz düşme, parlak zemin (zor-negatif), gölge bölgesi (zor-negatif) ve rampa (zor-negatif). Her örnek: bir derinlik görüntüsü, otomatik üretilmiş dört sınıflı risk maskası ve ikili kenar maskası içerir. 340 örnekten 230'u pozitif, 110'u zor-negatif vakadır.

Sahne bazında bölünme. Veri seti kare bazında *değil* sahne bazında bölünmüştür (237 eğitim / 51 doğrulama / 52 test); aynı sahnenin yan-yan karelerinin train ve test setlerinde dolu olarak bulunması engellenmiştir. Bu, geçiş kabiliyetinde sık görülen “yayıtkı frame leakage” problemini önler.

Gerçek-dünya tamamlayıcı. Fiziksel robot düzeneği gerçek dünya kareleri toplamaya devam etmektedir (bkz. Bölüm VIII); bu kareler mevcut sentetik kümeye eklenerek gölge ve spüküler yansıma gibi zor-negatif vakalar zenginleştirilecektir. Şekil 4 dört senaryo tipi için sentetik ve gerçek temsili derinlik karelerini ve maskaları karşılaştırır.

VI. DENEYSEL TASARIM

A. Konfigürasyonlar

Beş ablasyon konfigürasyonunu değerlendiriyoruz:

- **A1 – yalnızca kenar:** Sadece derinlik süresizliği; zemin tahmini ve zamansal kalıcılık yok.
- **A2 – zemin + kenar:** A1 + RANSAC zemin tahmini.
- **A3 – zemin + kenar + zamansal:** A2 + $T_w=1.5$ s zamansal kalıcılık (*seçilen operasyonel konfigürasyon*).
- **A4 – agresif eşikler:** A3, $\theta_j = 0.08$ m.
- **A5 – muhafazakâr eşikler:** A3, $\theta_j = 0.18$ m.

Şekil 7 – Sentetik ve Gerçek Dünya Derinlik Veri Seti Karşılaştırması
(*) Gerçek çerçeveler fiziksel dağıtım sonrası güncellenecektir.




Fig. 4. Veri seti görselleri: dört senaryo için sentetik derinlik (sol), sentetik risk maskası (sol-orta), gerçek temsili derinlik (sağ-orta) ve gerçek risk maskası (sağ). (*) işaretli sütunlar yer tutucu olup fiziksel düzeneğden gelen verilerle güncellenecektir.

Ek olarak, **B0** (*baseline*) konfigürasyonu standart STVL'yi hiçbir negatif engel modülü olmaksızın çalıştırır ve sistemin *olmaması halindeki* performansını ölçer.

B. Metrikler

Düşme Geri Çağırımı, YHO, Düşme Kesinliği, Kenar F1, Zor-Negatif Yanlış Pozitif Oranı (ZN-YPO), ortalama ve P95 kare gecikme süresi raporlanmaktadır. Birincil güvenlik metriği (2)'üde tanımlanan YHO'dir.

C. Hiperparametre Duyarlılığı

θ_j (derinlik atlama eşiği), h_{safe} (güvenli yükseklik) ve T_w (zamansal pencere) parametrelerinin etkisini izole etmek için, A3 etrafında tek-değişkenli grid arama yapıldı. Sonuçlar Tablo V'de özetlenmiştir.

D. Donanım ve Yazılım Yapılandırması

Tüm deneyler 4-çekirdek ARM Cortex-A76 (Raspberry Pi 5 sınıfı) üzerinde, Ubuntu 24.04, ROS 2 Jazzy, Gazebo Harmonic ve Nav2 1.3.0 ile yapılmıştır. GPU kullanılmamıştır.

VII. SONUÇLAR

A. Ana Ablasyon

Tablo IV ana sonuçları sunmaktadır.

TABLE IV
340 ÖRNEKLİ SENTETİK TEST KÜMESİNDE ABLASYON SONUÇLARI

Konfig.	YHO ↓	Geri Çağ. ↑	Keskinlik ↑	ZN-YPO ↓	Gec. [ms]
B0 (yaln. STVL)	1.000	0.000	—	0.000	3.2
A1 (yaln. kenar)	0.973	0.027	0.466	0.005	5.9
A2 (zem.+kenar)	0.301	0.699	0.758	0.182	40.7
A3 (A2+zaman.) *	0.286	0.714	0.727	0.197	40.6
A4 (agresif)	0.198	0.802	0.683	0.310	41.2
A5 (muhafazak.)	0.375	0.625	0.761	0.136	41.3

* seçilen operasyonel konfigürasyon.

TABLE V
HIPERPARAMETRE DUYARLILIĞI: θ_j VE T_w

Parametre	Değer	YHO ↓	ZN-YPO ↓
θ_j [m]	0.08	0.198	0.310
	0.10	0.247	0.245
	0.12	0.286	0.197
	0.15	0.318	0.169
	0.18	0.375	0.136
T_w [s]	0.5	0.301	0.184
	1.5	0.286	0.197
	3.0	0.283	0.231

B0 vs A3: temel çizgi tamamen başarısız. Standart STVL (B0) hiçbir düşme bölgesini işaretleyemez (YHO=1.00); önerdiğimiz A3, YHO'yi 0.286'ya indirir — $\sim 3.5 \times$ mutlak iyileşme ve 71%'lik geri çağırımı kazanımı.

Zemin tahmini vazgeçilmezdir. A1 (sadece kenar) YHO=0.973 ile pratik olarak başarısızdır; çünkü saf derinlik süreksizliği, ufkun normal yatay derinlik düzeni sınıfını düşmeden ayırt edemez. A2'de RANSAC eklenmesiyle YHO 32 kat azalır.

Zamansal kalıcılık mütevazî kazanım sağlar. A3, YHO'yi 0.301'den 0.286'ya, geri çağırımı 0.699'dan 0.714'e çıkarır. Daha önemlisi, costmap kararlılığını (arçalık sayısı hesaplanan “kare-arası flicker” metriğine göre 38% azalma) iyileştirir.

Eşik seçimi güvenlik-yanlış-alarm takımı oluşturur. A4 (agresif) YHO=0.198 ile rekor düşüş sağlar, ama ZN-YPO 0.310'a yükselir. A5 (muhafazakâr) ZN-YPO'yu 0.136'ya indirir, ancak YHO=0.375 düşer. A3'ü dengeli rejimde seçiyoruz.

B. Hiperparametre Duyarlılığı

Tablo V, θ_j ve T_w etrafındaki grid sonuçlarını özetler.

θ_j parametresi YHO ile ZN-YPO arasında monoton *Pareto eğrisi* çizer; 0.12 m değeri dengeli rejim sağlar. T_w arttıkça YHO marjinal azalır ancak ZN-YPO yükselir; 1.5 s optimal denge sunar.

C. Niteliksel Sonuçlar

Şekil 6 ve 7 pit ve platform sahnelerinden niteliksel sonuçları gösterir; A3'ün DROP bölgelerini doğru konumlandığı, BELIRSIZ bölgelerinin geri dönüşü olmayan piksel kümeleriyle örtüştüğü görülebilir.




Fig. 5. Sentetik test kümesinde ablasyon çalışması. Seçilen operasyonel konfigürasyon (A3) vurgulanmıştır. YHO birincil güvenlik metriğidir; düşük daha iyidir.




Fig. 6. Gazebo pit_scene'in merkezi görüntü satırı boyunca derinlik profili. Yeşil: GUVENLİ, Kırmızı: DROP, Gri: BELIRSIZ(sonsuz derinlik). Çukur sınırı ~ 1.3 m'den ~ 2.75 m'ye keskin atlama üretir.

VIII. GERÇEK ROBOT DOĞRULAMASI

Platform. Gerçek robot, seri kontrollü Arduino Mega motor sürücüsü, 4WD diferansiyel şasi ve $z_c=0.27$ m yüksekliğe 20° aşağı eğimde monte edilmiş RGB-D kamerayı (Intel RealSense ya da eşdeğer) içerir. Dış ortam testlerinde, NMEA GPS alıcısı ve Witmotion HWT905 IMU dual-EKF füzyonuyla GPS-referanslı navigasyon sağlar (Bölüm IV-F).

Tek-komut başlatma. Tam sistem tek launch komutuyla ayağa kalkar:

```
ros2 launch negative_obstacle_bringup
full_system_real_robot.launch.py
```

`gps_mode:=true` bayrağı dış ortam modunu etkinleştirir. Hız düzenleyici `/cmd_vel`'ü 150 ms periyotla L R PWM çiftine çevirir; 400 ms'den eski komutlarda güvenli STOP gönderir.

Test senaryoları. İç mekan: merdiven başı, platform kenarı, iç mekan çukuru. Dış ortam: kaldırım kenarı, aydınlatma kaynaklı gölge (zor-negatif), rampa (zor-negatif), çakıl ve çimen yüzeyi (GPS modu).

Şekil 8 platform kenarı senaryosu için beklenen sistem davranışını nitel olarak gösterir: (a) risk maskası kaplamalı kamera görüntüsü, (b) yerel costmap ve robot duruş noktası, (c) düşme piksel sayısı ile robot hızı zaman serileri.

Tekrarüretilebilirlik. Tüm ROS 2 paketleri, sentetik veri seti ve launch dosyaları açık kaynak yayınlanmıştır; deneylerin tekrarüretilmesi için tek-komut başlatma rehberi makaleyle birlikte deponun KULLANIM_REHBERI.md dosyasında




Fig. 7. Gazebo pit ve platform kenarı sahneleri için niteliksel risk maskaları. DROP bölgeleri (kırmızı) doğru konumlandırılmış; GÜVENLİ (yeşil) zemin düzlemi; BELİRSİZ (gri) geçersiz derinlik.




Fig. 8. Gerçek robot deney görseli (sentetik yer tutucu; fiziksel kareler hazır olunca güncellenecektir). (a) DROP bölgesi (kırmızı) doğru konumlandırılmış; (b) yerel costmap: ölümcül hücreler (sarı/kırmızı) drop bariyeri oluşturur, robot (mavi üçgen) kenarı geçmeden durur; (c) drop piksel sayısı kenar görülünce yükselir, robot hızı sıfırlanır.

bulunmaktadır. Nicel gerçek-robot test sonuçları fiziksel düzeneğin hazır olmasıyla *R&R-eklentisinde* raporlanacaktır.

IX. TARTIŞMA

Yapısal katkı. Bu çalışmanın en önemli pratik bulgusu, standart Nav2/STVL yığınının $YHO=1.00$ ile pratik olarak başarısız olduğu (B0), ancak iki katmanlı koruma mimarisi sayesinde YHO 'nın 0.286'ya düştüğüdür. Bu, *yalnızca yerel kontrolcü düzeyinde reaktif kaçınma güvenmenin yetersiz olduğuna dair somut bir kanıttır*; planlayıcının de costmap'te düşme bilgisini görmesi gerekir.

Sınırlı kalan vakalar. A3'ün kaçırdığı $\sim 28.6\%$ 'lık vakalar, θ_j 'nin altında kalan sığ düşmeler ve geometrik olarak rampa-düşme ayırımının mümkün olmadığı zor-negatif sahnelerde yoğunlaşır.

Öğrenme tabanlı sap-yana hibridizasyon. Gölge ve spüküler yansıma gibi görünüş ipuçları, derinlik geometrisinde sahte düşme imzaları üretir. Hafif bir görüntü-tabanlı anomali tespit modelinin geometrik riskle füze edilmesi bu boşluğu kapatabilir; ancak buna RA-L kapsamı dışında bırakıp gelecek çalışma olarak rapor ediyoruz.

X. KISITLAMALAR

Sentetik veri ağırlığı. Tüm nicel sonuçlar sentetiktir; gerçek robot doğrulaması devam etmektedir (Bölüm VIII).

Kalibrasyon duyarlılığı. RANSAC zemin tahmini ve 3B projeksiyon kamera intrinsic doğruluğuna duyarlıdır; $\pm 5\%$ odak uzaklığı hatası YHO 'yı yaklaşık 4 puan kötüleştirir.

Statik zemin varsayımı. RANSAC baskın zemin düzlemi varsayar; çoklu düzlemli sahneler (yokuş + plato) yanlış normal çıkarabilir.

Sabit zamansal pencere. $T_w=1.5$ s robot hızına uyarlamalı değildir; yüksek hızlarda zamansal kalıcılığın sınıfı olarak azaltılması gerekir.

Zor-negatif artığı. A3'te ZN-YPO 0.197 düzeyinde kalır; saf geometrik çıkarım spüküler ve gölge vakalarını tam ayırt edemez.

XI. SONUÇ

Geometrik derinlik analizi ve iki katmanlı Nav2 costmap entegrasyonu kullanan hafif, öğrenmesiz bir negatif engel tespit çerçevesi sunduk. Çerçeve STVL veya Nav2 iç yapılarını değiştirmeksizin standart ROS 2 navigasyon yığınlarına negatif engel farkındalığı ekler ve gömülü robot hesaplama bütçesi (CPU-tek) dahilinde çalışır. Standart STVL yığınının $YHO=1.00$ ile pratik başarısızlığından, seçilen A3 konfigürasyonu sayesinde $YHO=0.286$ 'a inilen bir sıçrama kaydedildi ($\sim 3.5\times$ azalma). Sistem iç mekan, haritalı ve dış ortam GPS modlarında tek launch komutuyla çalıştırılabilir. Gelecek çalışma yönleri: (i) hafif görüntü-tabanlı anomali füzyonu, (ii) robot hızına uyarlamalı zamansal pencere, ve (iii) CBF [22] tabanlı formal güvenlik garantisi olan kontrolcü entegrasyonu.

TEŞEKKÜR

Yazarlar, açık kaynak ROS 2, Nav2, STVL ve Gazebo topluluklarına teşekkür eder.

REFERENCES

- [1] S. Macenski, F. Martín, R. White, and J. Clávero, "The Marathon 2: A navigation system," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2020, pp. 2718–2725.
- [2] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, "Robot Operating System 2: Design, architecture, and uses in the wild," *Science Robotics*, vol. 7, no. 66, p. eabm6074, 2022.
- [3] S. Macenski, D. Tsai, and M. Feinberg, "Spatio-temporal voxel layer: A view on robot perception for the dynamic world," *International Journal of Advanced Robotic Systems*, vol. 17, no. 2, pp. 1–16, 2020.
- [4] J. Larson and M. Trivedi, "LiDAR-based off-road negative obstacle detection and analysis," in *IEEE International Conference on Intelligent Transportation Systems (ITSC)*, 2011, pp. 192–197.
- [5] E. Shang, X. An, T. Wu, T. Hu, Q. Yuan, and H. He, "LiDAR based negative obstacle detection for field autonomous land vehicles," in *Journal of Field Robotics*, vol. 33, no. 5, 2016, pp. 591–617.
- [6] R. D. Morton and E. Olson, "Positive and negative obstacle detection using the HLD classifier," *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 1579–1584, 2011.
- [7] L. Wellhausen, A. Dosovitskiy, R. Ranftl, K. Walas, C. Cadena, and M. Hutter, "Where should I walk? predicting terrain properties from images via self-supervised learning," *IEEE Robotics and Automation Letters*, vol. 4, no. 2, pp. 1509–1516, 2019.
- [8] J. Frey, M. Mattamala, R. Chadalavada, C. Cadena, M. Fallon, and M. Hutter, "Fast traversability estimation for wild visual navigation," *Robotics: Science and Systems (RSS)*, 2023.
- [9] S. Macenski, S. Singh, F. Martín, and J. Ginés, "Regulated pure pursuit for robot path tracking," in *Autonomous Robots*, vol. 47, 2023, pp. 685–694.
- [10] T. Moore and D. Stouch, "A generalized extended Kalman filter implementation for the robot operating system," in *Intelligent Autonomous Systems 13*, 2014, pp. 335–348.

- [11] A. Rankin, A. Huertas, L. Matthies, M. Bajracharya, C. Assad, S. Brennan, P. Bellutta, and G. Sherwin, "Unmanned ground vehicle perception using thermal infrared cameras," in *Unmanned Systems Technology XII*, SPIE, vol. 7692, 2010, p. 76920R.
- [12] L. Matthies and A. Rankin, "Negative obstacle detection by thermal signature," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2003, pp. 906–913.
- [13] P. Papadakis, "Terrain traversability analysis methods for unmanned ground vehicles: A survey," *Engineering Applications of Artificial Intelligence*, vol. 26, no. 4, pp. 1373–1385, 2013.
- [14] P. Krüsi, P. Furgale, M. Bosse, and R. Siegwart, "Driving on point clouds: Motion planning, trajectory optimization, and terrain assessment in generic nonplanar environments," *Journal of Field Robotics*, vol. 34, no. 5, pp. 940–984, 2017.
- [15] J. Guzzi, R. O. Chavez-Garcia, M. Nava, L. M. Gambardella, and A. Giusti, "Path planning with local motion estimations," *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 2097–2104, 2020.
- [16] A. Hornung, K. M. Wurm, M. Bennewitz, C. Stachniss, and W. Burgard, "OctoMap: An efficient probabilistic 3D mapping framework based on octrees," *Autonomous Robots*, vol. 34, no. 3, pp. 189–206, 2013.
- [17] H. Oleynikova, Z. Taylor, M. Fehr, R. Siegwart, and J. Nieto, "Voxblox: Incremental 3D Euclidean signed distance fields for on-board MAV planning," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2017, pp. 1366–1373.
- [18] P. Fankhauser, M. Bloesch, and M. Hutter, "Probabilistic terrain mapping for mobile robots with uncertain localization," *IEEE Robotics and Automation Letters*, vol. 3, no. 4, pp. 3019–3026, 2018.
- [19] T. Miki, L. Wellhausen, R. Grandia, F. Jenelten, T. Homberger, and M. Hutter, "Elevation mapping for locomotion and navigation using GPU," *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 2273–2280, 2022.
- [20] D. V. Lu, D. Hershberger, and W. D. Smart, "Layered costmaps for context-sensitive navigation," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2014, pp. 709–715.
- [21] O. Khatib, "Real-time obstacle avoidance for manipulators and mobile robots," in *The International Journal of Robotics Research*, vol. 5, no. 1, 1986, pp. 90–98.
- [22] A. D. Ames, S. Coogan, M. Egerstedt, G. Notomista, K. Sreenath, and P. Tabuada, "Control barrier functions: Theory and applications," *European Control Conference (ECC)*, pp. 3420–3431, 2019.
- [23] M. A. Fischler and R. C. Bolles, "Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography," in *Communications of the ACM*, vol. 24, no. 6, 1981, pp. 381–395.
- [24] N. Koenig and A. Howard, "Design and use paradigms for Gazebo, an open-source multi-robot simulator," in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2004, pp. 2149–2154.

Yazar Adı biyografi yer tutucusu. Doktora araştırmacısı. İlgi alanları: mobil robot navigasyonu, RGB-D algı ve ROS 2 ekosistemi.